NLP Solutions

Student Name: Mahdi Al-Mahdi

Doctor Name: Dr. Abdullah

Course: NLP

Date: 4 / 2 / 2026

القسم الأول: أسئلة الاختيار من متعدد (المفاهيم الأساسية)

1. الهدف الأساسي من **NLP** هو:

أ) تحليل الصور

ب) فهم اللغة البشرية

ج) تحسين الشبكات

د) ضغط البيانات

2. Tokenization تعني:

أ) ترجمة النص

ب) تقسيم النص

ج) ضغط النص

د) حذف الكلمات

3. Stop Words هي:

أ) كلمات نادرة

ب) كلمات شائعة قليلة القيمة

ج) كلمات تقنية

د) كلمات طويلة

4. TF-IDF يستخدم لـ:

أ) الترجمة

ب) تمثيل النص

ج) تصنيف الصور

د) ضغط البيانات

5. Bag of Words:

أ) يحافظ على ترتيب الكلمات

ب) يهمل الترتيب

ج) يستخدم الشبكات العصبية

د) يعتمد على السياق

6. أي نموذج يعتمد على السياق؟

أ) TF-IDF

ب) Bag of Words

ج) BERT

د) Count Vector

7. Lemmatization:

أ) تقطيع النص

ب) تحويل الكلمة لأصلها

ج) حذف الكلمات

د) ضغط النص

8. Word2Vec ينتج:

أ) صور

ب) متجهات

ج) جمل

د) قواعد

9. أي خوارزمية مناسبة لتصنيف النص؟

أ) KNN

ب) Naive Bayes

ج) Decision Tree

د) جميع ما سبق

10. NER تعني:

أ) تحليل المشاعر

ب) التعرف على الكيانات

ج) الترجمة

د) تصنيف النص

11. Overfitting يعني:

أ) نموذج ضعيف

ب) نموذج يحفظ البيانات

ج) نموذج سريع

د) نموذج بسيط

12. Underfitting يعني:

أ) نموذج بسيط جداً

٧) نموذج معقد

ج) نموذج دقيق

د) نموذج سريع

13. Embedding هو:

أ) صورة

ب) تمثيل رقمي للكلمات

ج) نص

د) خوارزمية

14. Language Model هدفه:

أ) الترجمة

ب) توقع الكلمة التالية

ج) ضغط النص

د) حذف الكلمات

15. Transformer يعتمد على:

أ) CNN

ب) RNN

ج) **Attention**

د) KNN

16. Attention يساعد في:

أ) حذف الكلمات

ب) التركيز على الكلمات المهمة

ج) ضغط النص

د) تحويل النص

17. POS Tagging:

أ) ترجمة

ب) تحديد نوع الكلمة

ج) حذف الكلمات

د) تحليل الصور

18. أي مما يلي Unsupervised؟

أ) Classification

ب) **Clustering**

ج) Regression

د) Decision Tree

19. Cosine Similarity تستخدم لـ:

أ) الترجمة

ب) قياس التشابه

ج) تصنيف الصور

د) ضغط النص

20. GPT هو:

أ) نموذج لغة

ب) خوارزمية تصنيف

ج) قاعدة بيانات

د) نظام تشغيل

القسم الثاني: أسئلة نظرية (شروحات ومقارنات)

ينتقل هذا القسم من المعرفة السطحية إلى الفهم العميق للميكانيكا الداخلية لتقنيات معالجة اللغات الطبيعية.

1. اشرح مفهوم Tokenization مع مثال.

التقطيع **(Tokenization)** هو الخطوة الأولى والأساسية في أي خط أنابيب (Pipeline) لمعالجة اللغات الطبيعية. تتمثل في أخذ نص خام وتقسيمه إلى وحدات أصغر ذات معنى تسمى "Tokens". يمكن أن تكون هذه الوحدات كلمات، أجزاء من الكلمات (Subwords)، أو حتى حروف (Characters). الهدف هو تحويل النص غير المهيكل إلى هيكل يمكن للخوارزميات التعامل معه.

> مثال عملي:
> النص الأصلي: `"الذكاء الاصطناعي يغير العالم!"`
> بعد *Word Tokenization*: `["الذكاء", "الاصطناعي", "يغير", "العالم", "!"]`

2. ما الفرق بين Stemming و Lemmatization؟

كلاهما تقنيات لتطبيع النص (Text Normalization) وتقليل الكلمات إلى جذرها، لكنهما يختلفان في المنهجية والدقة:

وجه المقارنة	**Stemming** (التجذير)	**Lemmatization** (الرد إلى الأصل المعجمي)
الآلية	يعتمد على قواعد قص (Heuristics) لقطع نهايات الكلمات (مثل إزالة "ون"، "ات").	يعتمد على تحليل صرفي وقاموس لغوي (Vocabulary) لفهم سياق الكلمة.
النتيجة	قد ينتج جذر غير موجود في اللغة (مثال: "دراسة" -> "دراس").	ينتج دائماً كلمة صحيحة لغوياً (Lemma) (مثال: "دراسة" -> "درس").
السرعة	سريع جداً (لأنه مجرد قص).	أبطأ (يتطلب بحثاً في القاموس وتحليلاً للسياق).
الاستخدام	محركات البحث البسيطة، تصنيف النصوص السريع.	الترجمة الآلية، المساعدات الصوتية، الأنظمة الدقيقة.

3. ما هو Bag of Words؟ وما عيوبه؟

Bag of Words (BoW) هو نموذج مبسط لتمثيل النصوص. يقوم بإنشاء "مفردات" (Vocabulary) من جميع الكلمات الفريدة في مجموعة المستندات، ثم يمثل كل مستند كمتجه (Vector) يحتوي على عدد مرات تكرار كل كلمة، متجاهلاً الترتيب والقواعد.

عيوبه الرئيسية:

- **فقدان السياق والترتيب:** الجملتان "الرجل أكل سمكة" و "سمكة أكلت الرجل" سيكون لهما نفس التمثيل الرياضي تماماً.
- **التناثر (Sparsity):** ينتج عنه مصفوفات ضخمة مليئة بالأصفار، مما يستهلك الذاكرة ويزيد من تعقيد الحسابات.
- **عدم إدراك الدلالة:** لا يدرك أن كلمتي "سعيد" و "مسرور" لهما نفس المعنى.

4. اشرح TF-IDF وكيف يعمل.

TF-IDF (Term Frequency-Inverse Document Frequency) هو تطوير لنموذج BoW. يهدف إلى تقييم مدى أهمية كلمة ما في مستند معين بالنسبة لمجموعة من المستندات (Corpus). يعمل عبر ضرب قيمتين:

1. **TF (تكرار المصطلح):** يقيس مدى تكرار الكلمة في المستند الحالي. (الكلمات المتكررة كثيراً في المستند تأخذ وزناً أعلى).

2. **IDF (تردد المستند العكسي):** يقيس مدى ندرة الكلمة في جميع المستندات. (الكلمات الشائعة جداً مثل "في"، "من" تأخذ وزناً يقترب من الصفر، بينما الكلمات النادرة تأخذ وزناً عالياً).

النتيجة: الكلمات التي تميز المستند (تتكرر فيه كثيراً ولكنها نادرة في باقي المستندات) تحصل على أعلى درجة TF-IDF.

5. ما هي Word Embeddings؟

تضمين الكلمات **(Word Embeddings)** هي تقنية حديثة تمثل الكلمات كمتجهات من الأرقام الحقيقية الكثيفة (Dense Vectors) في فضاء رياضي متعدد الأبعاد (عادة بين 100 إلى 300 بُعد). الميزة الثورية هنا هي أن الكلمات ذات المعاني المتشابهة تكون قريبة من بعضها في هذا الفضاء الرياضي.

على عكس BoW الذي يعطي متجهات متناثرة (Sparse)، التضمين يلتقط العلاقات الدلالية والنحوية. على سبيل المثال، العلاقة الرياضية الشهيرة:

`متجه(ملك) - متجه(رجل) + متجه(امرأة) ≈ متجه(ملكة)`.

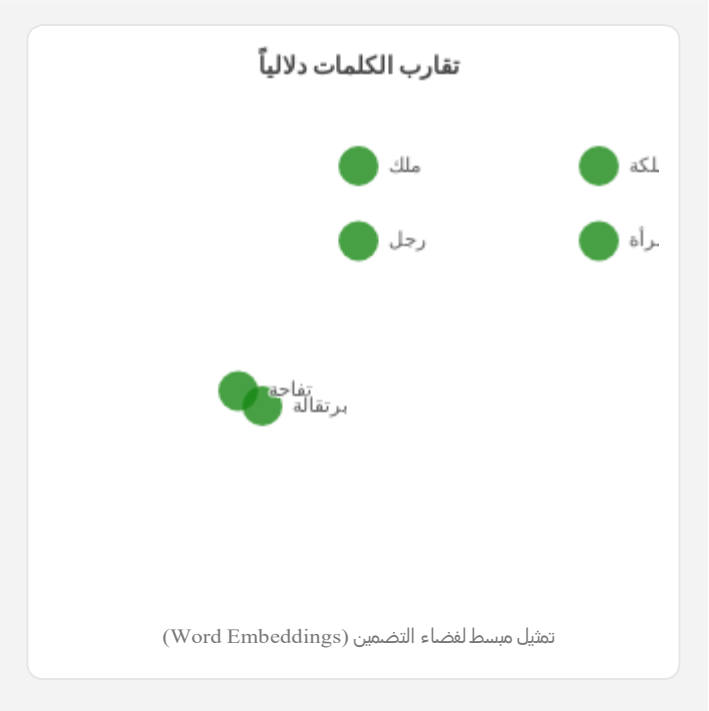

تمثيل مبسط لفضاء التضمين (Word Embeddings)

6. ما الفرق بين Word2Vec و GloVe؟

كلاهما خوارزميات لإنشاء Word Embeddings، لكنهما يختلفان في طريقة التدريب:

- **Word2Vec:** تم تطويره بواسطة Google. يعتمد على نماذج تنبؤية (Predictive Models) باستخدام شبكات عصبية ضحلة. يحاول التنبؤ بالكلمة المستهدفة من خلال سياقها (CBOW) أو التنبؤ بالسياق من خلال الكلمة المستهدفة (Skip-gram). يركز على النوافذ المحلية (Local Context Windows).
- **GloVe (Global Vectors):** تم تطويره بواسطة Stanford. يعتمد على نماذج إحصائية (Count-based Models). يقوم ببناء مصفوفة ضخمة لتكرار ظهور الكلمات معاً (Co-occurrence Matrix) في كامل مجموعة البيانات، ثم يقوم بتقليل أبعادها. يلتقط الإحصائيات العالمية (Global Statistics) للنص.

7. ما هي التحديات في اللغة العربية؟

معالجة اللغة العربية (ANLP) تواجه تحديات فريدة تجعلها من أصعب اللغات حاسوبياً:

- **التعقيد الصرفي (Morphological Richness):** الكلمة العربية الواحدة يمكن أن تحمل معنى جملة كاملة (مثال: "وسيكفيكهم" تتكون من حرف عطف + سين الاستقبال + فعل + فاعل مستتر + مفعول به أول + مفعول به ثانٍ).

- **غياب التشكيل (Diacritics):** معظم النصوص تكتب بدون حركات، مما يؤدي إلى غموض شديد (مثال: "علم" يمكن أن تكون عِلْم، عَلمَ، عَلِمَ، عَلَم).
- **تعدد اللهجات (Dialects):** وجود فجوة كبيرة بين الفصحى (MSA) واللهجات العامية التي تفتقر إلى قواعد إملائية موحدة.
- **نقص الموارد (Resource Scarcity):** مقارنة باللغة الإنجليزية، هناك نقص في البيانات المصنفة (Labeled Data) والقواميس المفتوحة عالية الجودة.

8. اشرح مفهوم Language Modeling.

نمذجة اللغة **(Language Modeling)** هي المهمة الأساسية التي تقوم عليها معظم تطبيقات الذكاء الاصطناعي التوليدي اليوم. رياضياً، نموذج اللغة هو نظام يحدد التوزيع الاحتمالي لتسلسل من الكلمات. بعبارة أبسط، هدفه هو التنبؤ بالكلمة التالية في جملة بناءً على الكلمات التي سبقتها.

إذا أعطينا النموذج الجملة: "ذهب الطالب إلى..."، فإن النموذج سيحسب احتمالات الكلمات الممكنة، وسيعطي كلمة "المدرسة" أو "الجامعة" احتمالًا أعلى بكثير من كلمة "المريخ". النماذج الحديثة مثل GPT هي في جوهرها نماذج لغة ضخمة (LLMs).

9. ما هو Attention Mechanism؟

آلية الانتباه **(Attention Mechanism)** هي ابتكار ثوري مستوحى من الإدراك البشري. عند قراءة جملة طويلة، لا يعطي الإنسان نفس الأهمية لكل كلمة، بل يركز (ينتبه) على كلمات محددة لفهم السياق.

في الشبكات العصبية، تقوم هذه الآلية بحساب "أوزان انتباه" (Attention Weights) ديناميكية. عند ترجمة كلمة معينة، يسمح الانتباه للنموذج بالنظر إلى جميع الكلمات في الجملة الأصلية وتحديد أي منها هو الأكثر صلة بالكلمة الحالية، مما يحل مشكلة نسيان المعلومات في الجمل الطويلة التي كانت تعاني منها النماذج القديمة.

10. ما الفرق بين RNN و Transformer؟

الميزة	RNN (الشبكات العصبية المتكررة)	Transformer (المحولات)
طريقة المعالجة	تسلسلية (Sequential): يعالج الكلمات كلمة تلو الأخرى.	متوازية (Parallel): يعالج جميع الكلمات في نفس الوقت.
السرعة والتدريب	بطيء جداً في التدريب ولا يستفيد من وحدات معالجة الرسومات (GPUs) بشكل كامل.	سريع جداً في التدريب، مصمم للعمل بكفاءة عالية على الـ GPUs.
التبعيات الطويلة	يعاني من مشكلة تلاشي التدرج (Vanishing Gradient)، ينسى بداية الجملة الطويلة.	ممتاز في التقاط التبعيات الطويلة بفضل آلية الانتباه الذاتي (Self-Attention).

11. ما هو NER مع مثال؟

التعرف على الكيانات المسماة **(Named Entity Recognition - NER)** هو مهمة استخراج المعلومات من النص وتصنيفها إلى فئات محددة مسبقاً مثل أسماء الأشخاص، المنظمات، المواقع، التواريخ، والمبالغ المالية.

> مثال:
> النص: *"أعلن تيم كوك في مؤتمر أبل الذي عقد في كاليفورنيا يوم الثلاثاء عن أرباح بلغت 10 مليار دولار."*
> مخرجات ***NER:***
> - تيم كوك: `[PERSON]` *(شخص)*
> - أبل: `[ORGANIZATION]` *(منظمة)*
> - كاليفورنيا: `[LOCATION]` *(موقع)* -
> الثلاثاء: `[DATE]` *(تاريخ)*
> - *10* مليار دولار: `[MONEY]` *(مال)*

12. اشرح POS Tagging.

وسم أجزاء الكلام **(Part-of-Speech Tagging)** هو عملية تحليل النص وتعيين علامة نحوية (Tag) لكل كلمة بناءً على دورها في الجملة وسياقها. العلامات تشمل: اسم (Noun)، فعل (Verb)، صفة (Adjective)، ظرف (Adverb)، حرف جر (Preposition)، إلخ.

أهميته تكمن في إزالة الغموض. مثلًا كلمة "ذهب" يمكن أن تكون فعلًا (ذهب الرجل) أو اسماً (خاتم من ذهب). الـ POS Tagger يحدد النوع الصحيح بناءً على السياق، مما يساعد في مهام مثل الترجمة وتحليل المشاعر.

13. ما هو Sentiment Analysis؟

تحليل المشاعر **(Sentiment Analysis)**، ويسمى أيضاً التنقيب عن الآراء (Opinion Mining)، هو استخدام معالجة اللغات الطبيعية لتحديد النغمة العاطفية وراء سلسلة من الكلمات. الهدف هو تصنيف النص إلى: إيجابي (Positive)، سلبي (Negative)، أو محايد (Neutral).

تستخدمه الشركات بكثرة لتحليل مراجعات العملاء، التغريدات على تويتر، وردود الفعل على المنتجات لمعرفة رضا العملاء بشكل آلي.

14. ما هو Overfitting وكيف تعالجه؟

التخصيص الزائد **(Overfitting)** يحدث عندما يتدرب النموذج لفترة طويلة جداً أو يكون معقداً جداً، فيبدأ في حفظ بيانات التدريب (بما في ذلك الضوضاء والتفاصيل العشوائية) بدلًا من تعلم الأنماط العامة. النتيجة: أداء ممتاز على بيانات التدريب، وأداء سيء جداً على البيانات الجديدة (بيانات الاختبار).

طرق العلاج في NLP:

- **Dropout:** إيقاف تفعيل نسبة عشوائية من الخلايا العصبية أثناء التدريب لمنع الاعتماد المفرط على مسارات معينة.
- **Early Stopping:** إيقاف التدريب بمجرد أن يبدأ أداء النموذج في الانخفاض على مجموعة التحقق (Validation Set).
- **Data Augmentation:** زيادة حجم البيانات (مثلًا عبر الترجمة العكسية Back-translation أو استبدال المرادفات).
- **Regularization (L1/L2):** إضافة عقوبة رياضية للأوزان الكبيرة في الشبكة.

15. ما الفرق بين Supervised و Unsupervised في NLP؟

- التعلم الخاضع للإشراف **(Supervised Learning):** النموذج يتدرب على بيانات موسومة *(Labeled)*. أي أن الإجابة الصحيحة موجودة مسبقاً. **أمثلة في NLP:** تصنيف البريد المزعج (البيانات مصنفة كـ Spam أو Not Spam)، تحليل المشاعر، التعرف على الكيانات (NER).
- التعلم غير الخاضع للإشراف **(Unsupervised Learning):** النموذج يتدرب على بيانات غير موسومة *(Unlabeled)*. النموذج يحاول اكتشاف الأنماط والهياكل المخفية بنفسه. **أمثلة في NLP:** نمذجة المواضيع (Topic Modeling مثل LDA)، تجميع المستندات (Clustering)، وتدريب نماذج اللغة الأساسية (مثل تدريب GPT على نصوص الإنترنت الخام للتنبؤ بالكلمة التالية).

القسم الثالث: أسئلة عملية وتحليلية

هذا القسم يركز على التطبيق العملي للمفاهيم، من العمليات الحسابية البسيطة إلى تصميم خطوط الأنابيب (Pipelines).

1. قم بعمل Tokenization للجملة: "الذكاء الاصطناعي يغير العالم"

بافتراض استخدام Word Tokenization قياسي (التقسيم بناءً على المسافات):

```
Input: "الذكاء الاصطناعي يغير العالم"
Output: ["الذكاء", "الاصطناعي", "يغير", "العالم"]
```

2. احذف Stop Words من الجملة: "أنا أريد أن أتعلم معالجة اللغات الطبيعية"

بافتراض قائمة كلمات التوقف العربية القياسية التي تتضمن الضمائر وحروف الجر وأدوات النصب (أنا، أن):

```
Input: "أنا أريد أن أتعلم معالجة اللغات الطبيعية"
Stop Words to remove: ["أن" ,"أنا"]
Output: ["الطبيعية" ,"اللغات" ,"معالجة" ,"أتعلم" ,"أريد"]
```

3. حساب IDF تقريبياً

المعطيات: عدد المستندات الكلي (N) = 1000، عدد المستندات التي تحتوي على الكلمة (df) = 50.

المعادلة: $IDF = \log\left(\frac{N}{df}\right)$

$IDF = \log\left(\frac{1000}{50}\right)$

$IDF = \log(20)$

$IDF \approx 2.9957$ (باستخدام اللوغاريتم الطبيعي) أو ≈ 1.301 (باستخدام لوغاريتم الأساس 10).

4. احسب Cosine Similarity بين متجهين بسيطين

مثال: لنحسب التشابه بين المتجه `A = [2, 1]` والمتجه `B = [1, 3]`.

المعادلة: $\text{Cosine Similarity} = \frac{A \cdot B}{\|A\| \times \|B\|}$

1. الضرب النقطي (Dot Product): $A \cdot B = (2 \times 1) + (1 \times 3) = 2 + 3 = 5$
2. طول المتجه A (Magnitude): $\|A\| = \sqrt{2^2 + 1^2} = \sqrt{4 + 1} = \sqrt{5} \approx 2.236$
3. طول المتجه B (Magnitude): $\|B\| = \sqrt{1^2 + 3^2} = \sqrt{1 + 9} = \sqrt{10} \approx 3.162$
4. الحساب النهائي: $\frac{5}{\sqrt{5} \times \sqrt{10}} = \frac{5}{\sqrt{50}} = \frac{5}{5\sqrt{2}} = \frac{1}{\sqrt{2}}$

$\text{Cosine Similarity} \approx 0.707$

5. لديك بيانات نصية: كيف تحولها إلى أرقام؟

عملية تحويل النص إلى أرقام تسمى **Vectorization**. الخطوات المتبعة تعتمد على تعقيد المهمة:

1. للمهام البسيطة **(Baseline):** استخدام (Bag of Words) `CountVectorizer` أو `TfidfVectorizer`. هذه الطرق تنشئ مصفوفات متناثرة بناءً على التكرار.
2. للمهام المتوسطة (التقاط الدلالة): استخدام Word Embeddings مسبقة التدريب مثل Word2Vec أو GloVe أو FastText. يتم تحويل كل كلمة لمتجه، ثم أخذ المتوسط (Average) لمتجهات كلمات الجملة لتمثيل الجملة كاملة.
3. للمهام المتقدمة (فهم السياق): تمرير النص عبر نموذج لغة ضخم مثل BERT للحصول على تضمين سياقي (Contextual Embeddings) يمثل الجملة بأكملها بدقة عالية.

6. صمم Pipeline لمعالجة النصوص.

خط أنابيب (Pipeline) قياسي لمعالجة النصوص يتكون من المراحل التالية:

1. جمع البيانات **(Data Ingestion):** قراءة النصوص من قواعد البيانات أو ملفات CSV.
2. تنظيف النص **(Text Cleaning):** إزالة علامات الترقيم، الأرقام، الروابط (URLs)، والرموز التعبيرية. 3. التطبيع **(Normalization):** توحيد حالة الأحرف (Lowercasing في الإنجليزية)، إزالة التشكيل وتوحيد أشكال الهمزات في العربية.
4. التقطيع **(Tokenization):** تقسيم النص إلى كلمات.
5. إزالة كلمات التوقف **(Stop Words Removal):** تصفية الكلمات غير المهمة. 6. التجذير/الرد للأصل **(Stemming/Lemmatization):** إرجاع الكلمات لأصولها.
7. استخراج الميزات **(Feature Extraction/Vectorization):** تحويل النص المنظف إلى أرقام (TF-IDF أو Embeddings).
8. النمذجة **(Modeling):** إدخال الأرقام إلى خوارزمية تعلم الآلة.

7. لديك Dataset صغير: أي نموذج تختار ولماذا؟

النموذج المختار: خوارزميات تعلم الآلة الكلاسيكية مثل **Naive Bayes** أو **Support Vector Machines (SVM)** مع TF-IDF.

السبب: النماذج العميقة (Deep Learning) مثل Transformers تحتوي على ملايين المعلمات (Parameters) وتحتاج إلى كميات هائلة من البيانات لتتدرب دون الوقوع في مشكلة الـ Overfitting. النماذج الكلاسيكية أبسط، تتطلب بيانات أقل، وتعمل بكفاءة عالية كخط أساس (Baseline) للبيانات الصغيرة.

8. لديك Dataset كبير: ما النموذج الأفضل؟

النموذج المختار: نماذج التعلم العميق، وتحديداً **Transformers** (مثل BERT للتصنيف، أو نماذج Seq2Seq للترجمة).

السبب: هذه النماذج قادرة على التقاط الأنماط المعقدة والتبعيات طويلة المدى في البيانات الضخمة. كلما زادت البيانات، زادت قدرة هذه النماذج على التعميم وتحقيق دقة تتفوق بكثير على النماذج الكلاسيكية.

9. كيف تحسن دقة نموذج تصنيف نصوص؟

- تحسين جودة البيانات: تنظيف أفضل للنص، معالجة الأخطاء الإملائية، وإزالة الضوضاء.
- هندسة الميزات **(Feature Engineering):** استخدام N-grams (بدلًا من كلمات مفردة)، أو دمج ميزات إضافية مثل طول الجملة أو عدد علامات التعجب.
- تغيير طريقة التمثيل: الانتقال من TF-IDF إلى Word Embeddings (Word2Vec) أو Contextual Embeddings (BERT).

- ضبط المعلمات الفائقة **(Hyperparameter Tuning):** استخدام Grid Search أو Random Search لإيجاد أفضل إعدادات للنموذج (مثل معدل التعلم Learning Rate).
- معالجة عدم التوازن: إذا كانت الفئات غير متوازنة، استخدم تقنيات مثل SMOTE أو تعديل أوزان الفئات (Class Weights).

10. كيف تتعامل مع النصوص العربية؟

التعامل مع العربية يتطلب خطوات معالجة مسبقة (Preprocessing) مخصصة:

1. **إزالة التشكيل (Diacritics Removal):** لتوحيد الكلمات (إلا إذا كانت المهمة تتطلب التشكيل مثل تحويل النص إلى كلام TTS).
2. **تطبيع الحروف (Orthographic Normalization):** تحويل (أ، إ، آ) إلى (ا)، وتحويل (ة) إلى (ه)، و(ى) إلى (ي).
3. **إزالة التطويل (Tatweel Removal):** إزالة حرف المد (ـ) المستخدم للتنسيق (مثال: مـرحـبـاً -> مرحباً).
4. **استخدام أدوات مخصصة:** استخدام مكتبات مصممة للعربية مثل `CAMeL Tools` أو `Farasa` أو `PyArabic` للقيام بالـ Tokenization والـ Lemmatization بشكل دقيق يراعي الصرف العربي.

11. صمم نظام Sentiment Analysis.

تصميم مبسط:

1. **المدخلات:** مراجعات العملاء (نص).
2. **المعالجة المسبقة:** تنظيف النص، إزالة الروابط، التقطيع، وإزالة كلمات التوقف.
3. **التمثيل (Vectorization):** استخدام نموذج `TF-IDF` لتحويل النصوص إلى متجهات.
4. **النموذج:** تدريب مصنف `Logistic Regression` أو `Linear SVM` (سريع وفعال مع TF-IDF).
5. **المخرجات:** تصنيف المراجعة إلى (إيجابي، سلبي، محايد) مع نسبة الثقة (Confidence Score).

12. لديك مشكلة Overfitting: اقترح 3 حلول.

1. **تقليل تعقيد النموذج (Model Simplification):** تقليل عدد الطبقات المخفية (Hidden Layers) أو عدد الخلايا العصبية في الشبكة.
2. **إضافة Regularization:** استخدام تقنيات مثل L2 Regularization (Ridge) التي تعاقب الأوزان الكبيرة، أو إضافة طبقات `Dropout` في الشبكات العصبية.
3. **زيادة البيانات (Data Augmentation):** إذا لم تتمكن من جمع بيانات جديدة، قم بتوليد بيانات اصطناعية عبر استبدال الكلمات بمرادفاتها، أو استخدام الترجمة العكسية (ترجمة النص للغة أخرى ثم إعادته للغة الأصلية).

13. قارن بين Naive Bayes و Logistic Regression.

وجه المقارنة	Naive Bayes	Logistic Regression
النوع	نموذج توليدي (Generative). يعتمد على نظرية بايز.	نموذج تمييزي (Discriminative). يعتمد على دالة Sigmoid.
الافتراضات	يفترض "سذاجة" أن الميزات (اللمات) مستقلة تماماً عن بعضها.	لا يفترض استقلالية الميزات، يمكنه التعامل مع الميزات المترابطة.
الأداء مع البيانات الصغيرة	ممتاز جداً وسريع، يعمل جيداً حتى مع بيانات قليلة.	يحتاج إلى بيانات أكثر نسبياً لتجنب الـ Overfitting.
الاستخدام الشائع	تصنيف البريد المزعج (Spam Filtering).	تحليل المشاعر، التصنيف الثنائي العام.

14. لديك نصوص غير نظيفة: كيف تنظفها؟

النصوص غير النظيفة (Noisy Text) مثل تغريدات تويتر تتطلب تنظيفاً صارماً باستخدام التعابير النمطية (Regex):

- إزالة إشارات المستخدمين (Mentions) مثل `@username`.
- إزالة الروابط التشعبية (URLs) مثل `http://...`.
- إزالة أو استبدال الرموز التعبيرية (Emojis) بنصوص تعبر عنها (مثلاً 😂 -> [ابتسامة]).
- إزالة علامات التصنيف (Hashtags) أو الاحتفاظ بالنص داخلها فقط (مثال: #ذكاء_اصطناعي -> ذكاء اصطناعي).
- تصحيح الأخطاء الإملائية الشائعة باستخدام قواميس التصحيح.

15. صمم مشروع NLP كامل (من البداية للنهاية).

مشروع: نظام تصنيف تذاكر الدعم الفني آلياً

1. تحديد المشكلة: توجيه تذاكر العملاء آلياً إلى القسم المختص (فني، مالي، مبيعات). 2.
جمع البيانات: استخراج 10,000 تذكرة سابقة مصنفة يدوياً من نظام الـ CRM.
3. تحليل البيانات الاستكشافي (EDA): معرفة توزيع الفئات (هل قسم المبيعات لديه تذاكر أكثر بكثير من الفني؟)، ومعرفة طول النصوص.
4. المعالجة المسبقة: تنظيف النصوص، إزالة التوقيعات الآلية في نهاية الإيميلات، والـ Tokenization.
5. بناء النموذج:
   - الخط الأساسي *(Baseline)*: TF-IDF + SVM.
   - النموذج المتقدم: Fine-tuning لنموذج BERT مسبق التدريب (Pre-trained).

6. **التقييم:** استخدام مقاييس Accuracy, Precision, Recall, F1-Score. (التركيز على F1-Score إذا كانت البيانات غير متوازنة).
7. **النشر (Deployment):** تغليف النموذج كـ API باستخدام FastAPI أو Flask، وربطه بنظام الـ CRM.
8. **المراقبة (Monitoring):** تتبع أداء النموذج في الإنتاج وإعادة تدريبه دورياً عند انخفاض الدقة (Model Drift).

القسم الرابع: أسئلة اختيار من متعدد (مفاهيم متقدمة)

1. ما هو Byte Pair Encoding (BPE)؟

أ) خوارزمية ضغط نصوص

ب) طريقة Tokenization

ج) نموذج لغة

د) خوارزمية تصنيف

2. Subword Tokenization تستخدم لـ:

أ) حذف الكلمات

ب) التعامل مع الكلمات النادرة

ج) ترجمة النص

د) ضغط البيانات

3. ما هو n-gram؟

أ) نموذج عميق

ب) تسلسل من n كلمات

ج) خوارزمية

د) قاعدة بيانات

4. Bigram يعني:

أ) كلمة واحدة

ب) كلمتين

ج) ثلاث كلمات

د) أربع كلمات

5. **Trigram** يعني:

أ) كلمتين

ب) ثلاث كلمات

ج) أربع كلمات

د) خمس كلمات

6. **Perplexity** تستخدم لـ:

أ) قياس جودة النموذج اللغوي

ب) ضغط النص

ج) حذف الكلمات

د) تصنيف الصور

7. **BLEU Score** يستخدم في:

أ) تصنيف النص

ب) الترجمة الآلية

ج) تحليل المشاعر

د) clustering

8. **ROUGE** يستخدم في:

أ) الترجمة

ب) التلخيص

ج) التصنيف

د) التعلم العميق

9. Seq2Seq Model يستخدم في:

أ) التصنيف

ب) الترجمة

ج) clustering

د) PCA

10. Encoder يقوم بـ:

أ) توليد النص

ب) تمثيل الإدخال

ج) حذف الكلمات

د) ضغط الصور

11. Decoder يقوم بـ:

أ) تحليل الصور

ب) توليد النص

ج) حذف الكلمات

د) تصنيف البيانات

12. Masked Language Model:

أ) يتوقع الكلمة المحذوفة

ب) يترجم النص

ج) يصنف النص

د) يضغط البيانات

13. Autoregressive Model:

أ) يتوقع كل الكلمات دفعة واحدة

ب) يتوقع الكلمة التالية

ج) لا يستخدم سياق

د) نموذج ثابت

14. Transformer يتكون من:

أ) Encoder فقط

ب) Decoder فقط

ج) Encoder و Decoder

د) CNN

15. Self-Attention:

أ) يعتمد على الصور

ب) يربط الكلمات ببعضها

ج) يحذف الكلمات

د) يضغط النص

16. Positional Encoding يستخدم لـ:

أ) حذف الترتيب

ب) تمثيل ترتيب الكلمات

ج) ضغط النص

د) حذف الكلمات

17. Fine-tuning يعني:

أ) تدريب من الصفر

ب) تحسين نموذج جاهز

ج) حذف البيانات

د) ضغط النموذج

18. Transfer Learning:

أ) تدريب جديد

ب) نقل المعرفة

ج) حذف البيانات

د) تصنيف الصور

19. Zero-shot Learning:

أ) تدريب كامل

ب) بدون تدريب مباشر

ج) تعلم عميق

د) clustering

20. Few-shot Learning:

أ) بيانات كثيرة

ب) بيانات قليلة

ج) بدون بيانات

د) ضغط البيانات

القسم الخامس: أسئلة نظرية متقدمة

هذا القسم يفكك البنى المعمارية المعقدة للنماذج الحديثة ويشرح آليات عملها الداخلية.

1. اشرح Subword Tokenization ولماذا هي مهمة.

تقطيع الكلمات الفرعية **(Subword Tokenization)** هو حل وسط بين تقطيع الكلمات (Word-level) وتقطيع الحروف (Character-level). خوارزميات مثل BPE و WordPiece تقوم بتقسيم الكلمات النادرة أو المعقدة إلى أجزاء أصغر مألوفة.

أهميتها:

- حل مشكلة **OOV (Out-of-Vocabulary):** إذا واجه النموذج كلمة جديدة مثل "ChatGPT"، يمكنه تقسيمها إلى "Chat" و "G" و "PT" وفهمها بناءً على أجزائها.
- تقليل حجم القاموس: بدلًا من حفظ ملايين الكلمات، يمكن للنموذج حفظ 30,000 إلى 50,000 مقطع فرعي (Subwords) قادرة على تكوين أي كلمة في اللغة.
- التعامل مع اللغات الغنية صرفيًا: ممتازة للغات مثل العربية والتركية حيث تلتصق الضمائر وحروف الجر بالكلمة.

2. ما الفرق بين Autoregressive Models و Masked Language Models؟

وجه المقارنة	Autoregressive Models (مثل GPT)	Masked Language Models (مثل BERT)
آلية التدريب	التنبؤ بالكلمة التالية في التسلسل (من اليسار لليمين).	إخفاء كلمات عشوائية في الجملة والتنبؤ بها.
السياق (Context)	أحادي الاتجاه (Unidirectional). يرى فقط الكلمات السابقة.	ثنائي الاتجاه (Bidirectional). يرى الكلمات السابقة واللاحقة.
أفضل استخدام	توليد النصوص (Text Generation)، المحادثة، التلخيص.	فهم النصوص (NLU)، التصنيف، استخراج الكيانات (NER).

3. اشرح مفهوم Perplexity وكيف يتم استخدامه.

الحيرة **(Perplexity - PP)** هي المقياس القياسي لتقييم نماذج اللغة. رياضياً، هي الأس (Exponentiation) للإنتروبيا المتقاطعة (Cross-Entropy). بشكل مبسط، هي تقيس "مدى تفاجؤ" النموذج عند رؤية بيانات جديدة.

إذا كان النموذج يتوقع الكلمة التالية بدقة عالية، ستكون حيرته منخفضة. قاعدة عامة: كلما انخفضت قيمة الـ Perplexity، كان النموذج أفضل. يتم استخدامه أثناء تدريب النماذج لمقارنة أداء الإصدارات المختلفة (مثلًا نموذج بحيرة 20 أفضل من نموذج بحيرة 50).

4. ما الفرق بين BLEU و ROUGE بالتفصيل؟

- **BLEU (Bilingual Evaluation Understudy):**
  - الاستخدام: الترجمة الآلية.

- الآلية: يركز على الدقة **(Precision)**. يحسب كم عدد الـ n-grams في النص المولد (الآلي) التي ظهرت في النص المرجعي (البشري).
- الفلسفة: "هل الكلمات التي أنتجتها الآلة صحيحة وموجودة في الترجمة البشرية؟"

- **ROUGE (Recall-Oriented Understudy for Gisting Evaluation):**
  - الاستخدام: التلخيص الآلي.
  - الآلية: يركز على الاستدعاء **(Recall)**. يحسب كم عدد الـ n-grams في النص المرجعي (البشري) التي نجح النص المولد (الآلي) في التقاطها.
  - الفلسفة: "هل نجحت الآلة في التقاط جميع المعلومات المهمة الموجودة في الملخص البشري؟"

5. اشرح بنية Transformer بالتفصيل.

بنية المحول (Transformer) التي قدمتها جوجل عام 2017 تتكون من مكونين رئيسيين:

1. المشفر **(Encoder):** يتكون من طبقات متطابقة (عادة 6 أو أكثر). كل طبقة تحتوي على:
   - *Multi-Head Self-Attention:* لفهم العلاقات بين الكلمات.
   - *Feed-Forward Neural Network:* لمعالجة المخرجات بشكل غير خطي.

   يأخذ الـ Encoder النص المدخل ويحوله إلى مصفوفة من المتجهات الغنية بالسياق.
2. مفكك الشفرة **(Decoder):** يتكون أيضاً من طبقات متطابقة، لكنه يحتوي على آلية انتباه إضافية:
   - *Masked Self-Attention:* يمنع النموذج من "الغش" بالنظر إلى الكلمات المستقبلية أثناء التوليد.
   - *Encoder-Decoder Attention:* يركز على المخرجات القادمة من الـ Encoder (مثلاً التركيز على الكلمة الإنجليزية المناسبة أثناء توليد الكلمة العربية).

6. ما هو Self-Attention وكيف يعمل؟

الانتباه الذاتي (Self-Attention) هو الآلية التي تسمح للنموذج بحساب تمثيل لكل كلمة بناءً على علاقتها بجميع الكلمات الأخرى في نفس الجملة. يعمل عبر ثلاثة متجهات لكل كلمة:

- **Query (Q) - الاستعلام:** ما الذي تبحث عنه هذه الكلمة؟
- **Key (K) - المفتاح:** ما الذي تقدمه هذه الكلمة للكلمات الأخرى؟ **(V)**
- **Value - القيمة:** المعنى الفعلي للكلمة.

يتم حساب درجة التطابق (Score) بضرب Q للكلمة الحالية في K لجميع الكلمات الأخرى. الكلمات ذات التطابق العالي تمرر قيمتها (V) بقوة أكبر لتشكيل المعنى النهائي للكلمة الحالية.

7. ما هي Positional Encoding ولماذا نحتاجها؟

بما أن الـ Transformer لا يستخدم شبكات متكررة (RNN) ويعالج جميع الكلمات في نفس اللحظة (بالتوازي)، فإنه لا يعرف ترتيب الكلمات. (بالنسبة له "أكل الكلب القط" و "أكل القط الكلب" متطابقتان).

التشفير الموضعي (Positional Encoding) يحل هذه المشكلة عن طريق إضافة متجه رياضي (يُحسب غالباً باستخدام دوال الجيب وجيب التمام Sine/Cosine) إلى متجه الكلمة الأصلي (Embedding). هذا المتجه الإضافي يحمل معلومات حول موقع الكلمة (الأولى، الثانية، العاشرة)، مما يمنح النموذج إحساساً بالترتيب الزمني.

8. اشرح الفرق بين Encoder و Decoder في Transformer.

الفرق الجوهري يكمن في الهدف وآلية الانتباه:

- **Encoder:** هدفه الفهم. يرى الجملة بأكملها دفعة واحدة (ثنائي الاتجاه). الانتباه الذاتي فيه يسمح للكلمة بالنظر إلى ما قبلها وما بعدها بحرية تامة.
- **Decoder:** هدفه التوليد. يولد النص كلمة بكلمة. الانتباه الذاتي فيه "مُقنّع" (Masked)، مما يعني أن الكلمة الحالية يمكنها فقط النظر إلى الكلمات التي تم توليدها سابقاً، ولا يمكنها النظر إلى المستقبل.

9. ما هو Fine-tuning ولماذا هو مهم؟

الضبط الدقيق (Fine-tuning) هو أخذ نموذج لغة ضخم تم تدريبه مسبقاً على مليارات الكلمات (Pre-trained Model) وتدريبه لفترة إضافية قصيرة على مجموعة بيانات صغيرة ومحددة بمهمة معينة (مثل تصنيف المشاعر أو الإجابة على الأسئلة الطبية).

أهميته: يوفر كميات هائلة من الوقت، المال، والموارد الحسابية. بدلًا من تدريب نموذج من الصفر (مما يتطلب ملايين الدولارات وأشهراً من الحوسبة)، يمكنك الاستفادة من "المعرفة العامة" للنموذج وتخصيصها لمشكلتك في غضون ساعات.

10. ما هو Transfer Learning في NLP؟

التعلم الانتقالي هو المظلة الكبرى التي يندرج تحتها الـ Fine-tuning. الفكرة هي نقل المعرفة المكتسبة من مهمة المصدر (Source Task) إلى مهمة الهدف (Target Task). في NLP، مهمة المصدر غالباً ما تكون "نمذجة اللغة" (توقع الكلمة التالية في نصوص ويكيبيديا)، ومهمة الهدف تكون مهمتك الخاصة (مثل تصنيف التغريدات).

11. ما هو Zero-shot Learning مع مثال؟

التعلم بدون أمثلة **(Zero-shot Learning)** هو قدرة النموذج على تنفيذ مهمة لم يتم تدريبه عليها صراحةً، وذلك بالاعتماد فقط على فهمه للتعليمات (Prompt).

> مثال:
>
> أنت تعطي نموذج *GPT* النص التالي:
>
> `"صنف الجملة التالية إلى (رياضة، سياسة، اقتصاد): 'سجل اللاعب هدفاً رائعاً في الدقيقة التسعين'."`
>
> النموذج سيجيب: `"رياضة"`.
>
> النموذج فعل ذلك دون أن تعطيه أي أمثلة سابقة توضح كيف يتم التصنيف.

12. ما الفرق بين GPT و BERT؟

الميزة	BERT (من Google)	GPT (من OpenAI)
البنية (Architecture)	يستخدم الـ **Encoder** فقط من الـ Transformer.	يستخدم الـ **Decoder** فقط من الـ Transformer.
اتجاه القراءة	ثنائي الاتجاه (Bidirectional). يقرأ النص كاملًا.	أحادي الاتجاه (Unidirectional). يقرأ من اليسار لليمين.
هدف التدريب الأساسي	Masked Language Modeling (توقع الكلمات المخفية).	Autoregressive (توقع الكلمة التالية).
أفضل استخدام	فهم النص، التصنيف، استخراج المعلومات (NLU).	توليد النص، المحادثة، التلخيص (NLG).

13. اشرح Seq2Seq Model مع مثال.

نموذج **Sequence-to-Sequence** هو بنية مصممة لتحويل تسلسل من العناصر (مثل الكلمات) إلى تسلسل آخر. يتكون من Encoder يضغط المدخلات في متجه سياقي، و Decoder يفك ضغط هذا المتجه لتوليد

المخرجات.

> مثال *(الترجمة الآلية):*
> - المدخل ***(Sequence 1):*** *"How are you?"*
> - الـ ***Encoder:*** يعالج الكلمات ويحولها إلى متجه رياضي يمثل المعنى *(السؤال عن الحال)*. -
> الـ ***Decoder:*** يأخذ هذا المتجه ويبدأ في التوليد: "كيف" -> "حالك" -> "؟"
> - المخرج ***(Sequence 2):*** *"كيف حالك؟"*

14. ما هي التحديات في بناء Chatbot؟

- **إدارة السياق (Context Management):** تذكر ما قاله المستخدم في بداية المحادثة وربطه بالأسئلة الحالية (الذاكرة طويلة المدى).
- **التعامل مع الغموض (Ambiguity):** فهم قصد المستخدم الحقيقي عندما يستخدم لغة غير مباشرة أو ساخرة.
- **الهلوسة (Hallucination):** ميل النماذج التوليدية لاختراع معلومات غير صحيحة تبدو مقنعة.
- **التعامل مع اللغات واللهجات:** فهم اللهجات العامية والأخطاء الإملائية التي يكتب بها المستخدمون عادة في الدردشة.
- **الاستجابات الآمنة (Safety & Guardrails):** منع البوت من توليد محتوى مسيء أو تقديم نصائح طبية/قانونية خطيرة.

15. كيف تقيم نموذج NLP؟ (metrics)

يعتمد التقييم على نوع المهمة:

- **لمهام التصنيف (Classification):** Accuracy (الدقة العامة)، Precision (الدقة الإيجابية)، Recall (الاستدعاء)، F1-Score (المتوسط التوافقي بين Precision و Recall).
- **لنماذج اللغة (Language Models):** Perplexity (الحيرة)، Cross-Entropy Loss.
- **للترجمة الآلية (Translation):** BLEU Score، METEOR.
- **للتلخيص (Summarization):** ROUGE Score.
- **للمهام التوليدية الحديثة (LLMs):** التقييم البشري (Human Evaluation)، أو استخدام نماذج قوية لتقييم نماذج أخرى (LLM-as-a-Judge).

القسم السادس: أسئلة عملية وتصميم أنظمة (System Design)

هذا القسم مخصص لمهندسي الذكاء الاصطناعي، حيث نركز على كيفية دمج النماذج في أنظمة إنتاجية حقيقية قابلة للتوسع (Scalable).

1. لديك نص طويل: كيف تقوم بتلخيصه باستخدام NLP؟

هناك نهجان رئيسيان للتلخيص:

1. التلخيص الاستخراجي **(Extractive Summarization):**
   - **الآلية:** استخراج أهم الجمل من النص الأصلي كما هي.
   - **الطريقة:** استخدام خوارزميات مثل `TextRank` (مشابهة لـ PageRank من جوجل). يتم تمثيل الجمل كعقد في رسم بياني (Graph)، والروابط هي مدى التشابه بين الجمل. الجمل الأكثر ارتباطاً بغيرها تعتبر الأهم وتُستخرج.
2. التلخيص التجريدي **(Abstractive Summarization):**
   - **الآلية:** فهم النص وتوليد ملخص بكلمات جديدة (كما يفعل الإنسان).
   - **الطريقة:** استخدام نماذج `Seq2Seq` مبنية على Transformers مثل `BART` أو `T5` أو `GPT`. يتم تمرير النص الطويل كمدخل، ويقوم النموذج بتوليد الملخص.

2. صمّم نظام ترجمة آلية بسيط.

هندسة النظام **(Architecture):**

1. الواجهة الأمامية **(Frontend):** واجهة ويب بسيطة تستقبل النص وتحدد لغة المصدر والهدف.
2. المعالجة المسبقة **(API Backend):** تقطيع النص (Tokenization) باستخدام BPE للتعامل مع الكلمات غير المعروفة.
3. النموذج الأساسي: استخدام نموذج Transformer (Encoder-Decoder) مثل `MarianMT` (مفتوح المصدر وممتاز للترجمة).
4. الاستدلال **(Inference):** استخدام تقنية `Beam Search` أثناء التوليد لاختيار أفضل تسلسل للكلمات المترجمة بدلًا من اختيار الكلمة الأعلى احتمالًا فقط (Greedy Search).
5. المعالجة البعدية **(Post-processing):** تجميع الـ Tokens الفرعية لتكوين كلمات كاملة وإصلاح علامات الترقيم.

3. لديك بيانات متعددة اللغات: كيف تتعامل معها؟

- التعرف على اللغة **(Language Identification):** استخدام مكتبات مثل `fastText` لتحديد لغة كل مستند أولًا.
- النماذج متعددة اللغات **(Multilingual Models):** بدلًا من تدريب نموذج لكل لغة، استخدم نماذج دربت مسبقاً على لغات متعددة مثل (Multilingual BERT) `mBERT` أو `XLM-RoBERTa`. هذه النماذج تمتلك فضاء تضمين مشترك (Shared Embedding Space) حيث تكون الكلمات ذات المعنى نفسه من لغات مختلفة قريبة من بعضها.
- الترجمة كخطوة وسيطة: ترجمة جميع البيانات إلى لغة واحدة (مثلًا الإنجليزية) باستخدام API، ثم تطبيق نموذج NLP أحادي اللغة (مفيد إذا كانت الموارد للغات الأخرى ضعيفة).

4. كيف تبني Chatbot ذكي؟

لبناء Chatbot ذكي (وليس مبنيًا على القواعد)، نستخدم هندسة **RAG (Retrieval-Augmented Generation):**

1. قاعدة المعرفة **(Knowledge Base):** تحويل مستندات الشركة (PDFs, FAQs) إلى متجهات (Embeddings) وتخزينها في قاعدة بيانات متجهة (Vector Database) مثل `Pinecone` أو `ChromaDB`.
2. استقبال السؤال: عندما يسأل المستخدم، يتم تحويل سؤاله إلى متجه.
3. الاسترجاع **(Retrieval):** البحث في قاعدة البيانات المتجهة عن أقرب المستندات (Cosine Similarity) لسؤال المستخدم.
4. التوليد **(Generation):** إرسال المستندات المسترجعة + سؤال المستخدم كـ Prompt إلى نموذج لغة ضخم (LLM) مثل GPT-4 مع تعليمة: "أجب على السؤال بناءً على السياق المرفق فقط".

5. لديك مشكلة **Ambiguity** في النص: كيف تعالجها؟

الغموض (Ambiguity) مثل كلمة "عين" (عضو الإبصار، نبع الماء، الجاسوس) يعالج عبر فهم السياق:

- تجنب النماذج القديمة: لا تستخدم BoW أو Word2Vec القياسي (لأنه يعطي متجه واحد لكلمة "عين" بغض النظر عن معناها).
- استخدام **Contextual Embeddings:** استخدم نماذج مثل BERT. **BERT** يولد متجهاً مختلفاً لكلمة "عين" في جملة "شربت من عين الماء" مقارنة بجملة "أصابتني عين حاسدة"، لأنه يحسب المتجه بناءً على الكلمات المحيطة.
- **POS Tagging:** في بعض الحالات، معرفة نوع الكلمة (اسم أم فعل) يزيل الغموض النحوي.

6. كيف تتعامل مع **Out-of-Vocabulary (OOV) words**؟

الكلمات خارج القاموس هي الكلمات التي لم يرها النموذج أثناء التدريب.

- الحل القديم: استبدالها برمز خاص `[UNK]` (Unknown). هذا يؤدي إلى فقدان المعلومات.
- الحل الحديث (المعتمد): استخدام **Subword Tokenization** (مثل BPE أو WordPiece). إذا واجه النموذج كلمة "Bioinformatics" ولم تكن في القاموس، سيقسمها إلى "Bio" و "inform" و "atics"، وهي مقاطع غالباً ما تكون موجودة في القاموس، مما يسمح للنموذج باستنتاج المعنى.
- تصحيح الأخطاء الإملائية: غالباً ما تكون الـ OOV ناتجة عن أخطاء إملائية، لذا فإن تمرير النص على مصحح إملائي قبل المعالجة يقلل منها.

7. لديك **Dataset** غير متوازن: كيف تعالجه؟

عدم التوازن (مثلًا 95% من التغريدات محايدة و 5% سلبية) يجعل النموذج ينحاز للفئة الأكبر.

- على مستوى البيانات **(Data-level):**
  - *Oversampling:* تكرار عينات الفئة الأقل، أو استخدام تقنيات توليد بيانات اصطناعية مثل SMOTE أو توليد نصوص جديدة باستخدام LLMs.
  - *Undersampling:* تقليل عدد عينات الفئة الأكبر (يُنصح به فقط إذا كان لديك بيانات ضخمة جداً).
- على مستوى الخوارزمية **(Algorithm-level):**

- *Class Weights*: تعديل دالة التكلفة (Loss Function) لتعطي عقوبة أكبر بكثير للنموذج عندما يخطئ في تصنيف الفئة الأقل.
- على مستوى التقييم: لا تستخدم الـ Accuracy أبداً. استخدم **F1-Score** أو مساحة تحت المنحنى (AUC-ROC).

8. كيف تبني نظام NER باستخدام Deep Learning؟

الهندسة القياسية لـ **NER**:

1. التمثيل **(Embeddings)**: تحويل الكلمات إلى متجهات باستخدام BERT (للحصول على سياق قوي).
2. النموذج المتسلسل: تمرير المتجهات إلى طبقة `Bi-LSTM` (Bidirectional Long Short-Term Memory) لالتقاط التبعيات التسلسلية من كلا الاتجاهين.
3. طبقة التصنيف **(CRF)**: استخدام طبقة `CRF` (Conditional Random Fields) في النهاية. الـ CRF ممتاز لـ NER لأنه يتعلم القواعد التسلسلية (مثلًا: الكلمة التي تلي `[B-PERSON]` من المرجح جداً أن تكون `[I-PERSON]` وليس `[B-LOCATION]`).
4. النهج الحديث: ببساطة عمل Fine-tuning لنموذج BERT مسبق التدريب على مهمة Token Classification.

9. كيف تستخدم Transformer في مشروعك؟

لا تقم ببناء Transformer من الصفر إلا لأغراض تعليمية. في المشاريع الحقيقية:

1. استخدم مكتبة `transformers` **Hugging Face**.
2. ابحث في *Hugging Face Hub* عن نموذج مسبق التدريب يناسب لغتك ومهمتك (مثلًا `aubmindlab/bert-base-arabertv02` للغة العربية).
3. قم بتحميل النموذج والـ Tokenizer الخاص به.
4. قم بعمل **Fine-tuning** للنموذج على بياناتك الخاصة باستخدام واجهة API `Trainer` التي توفرها المكتبة، والتي تبسط عملية التدريب والتقييم.

10. كيف تختار بين BERT و GPT حسب المهمة؟

قاعدة ذهبية للاختيار:

- اختر **BERT** (أو مشتقاته مثل **RoBERTa**): إذا كانت المهمة تتطلب فهم النص. أمثلة: تصنيف النصوص، تحليل المشاعر، استخراج الكيانات (NER)، الإجابة على الأسئلة الاستخراجية (تحديد مكان الإجابة في النص). السبب: يقرأ النص في كلا الاتجاهين.
- اختر **GPT** (أو نماذج **LLM** المشابهة): إذا كانت المهمة تتطلب توليد النص. أمثلة: كتابة المقالات، التلخيص التجريدي، الترجمة، بناء Chatbots، وتوليد الأكواد البرمجية. السبب: مصمم للتنبؤ بالكلمة التالية بشكل تسلسلي.

11. لديك نصوص noisy: كيف تنظفها؟ (advanced level)

للتنظيف المتقدم (خاصة نصوص الويب أو السوشيال ميديا):

1. **إزالة HTML/Boilerplate:** استخدام مكتبات مثل `BeautifulSoup` أو `justText` لإزالة أكواد HTML والقوائم الجانبية والاحتفاظ بالنص الأساسي فقط.
2. **معالجة الـ Mojibake:** إصلاح مشاكل ترميز الحروف (Encoding) باستخدام مكتبات مثل `ftfy` (Fixes Text For You).
3. **التطبيع المتقدم:** تحويل الأرقام المكتوبة نصياً إلى أرقام (مثال: "خمسة وعشرون" -> 25)، وتوحيد التواريخ إلى صيغة قياسية.
4. **التعامل مع الكلمات المدمجة:** استخدام خوارزميات Word Segmentation لفصل الكلمات التي نسى الكاتب وضع مسافة بينها (خاصة في الهاشتاجات).

12. كيف تحسن سرعة inference لنموذج NLP؟

نماذج Transformers بطيئة وثقيلة. لتسريعها في بيئة الإنتاج (Production):

- **التكميم (Quantization):** تقليل دقة الأوزان من 32-bit float إلى 8-bit integer. يقلل حجم النموذج للربع ويسرع الحسابات مع فقدان طفيف جداً في الدقة.
- **التقليم (Pruning):** إزالة الروابط (الأوزان) التي تقترب قيمتها من الصفر في الشبكة العصبية، مما يقلل العمليات الحسابية.

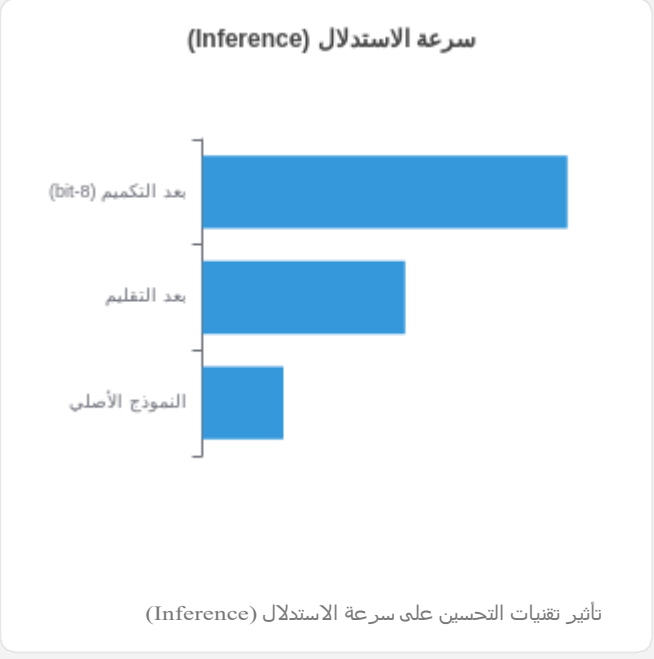

تأثير تقنيات التحسين على سرعة الاستدلال (Inference)

- **تقطير المعرفة (Knowledge Distillation):** تدريب نموذج صغير وسريع (Student) ليقلد سلوك نموذج ضخم وبطيء (Teacher). مثال: `DistilBERT`.

- **استخدام محركات استدلال محسنة:** تحويل النموذج إلى صيغة `ONNX` أو استخدام `TensorRT` من Nvidia لتسريع التنفيذ على الأجهزة.

13. صمّم نظام Question Answering.

نظام QA استخراجي **(Extractive QA):**

1. **المدخلات:** سؤال المستخدم + فقرة نصية (Context) تحتوي على الإجابة.
2. **النموذج:** نموذج BERT تم عمل Fine-tuning له على مجموعة بيانات SQuAD (Stanford Question Answering Dataset).
3. **الآلية:** النموذج لا يولد نصاً جديداً، بل يتوقع مؤشر البداية *(Start Token)* و مؤشر النهاية *(End Token)* للإجابة داخل الفقرة النصية.
4. **المخرجات:** استخراج النص الواقع بين مؤشري البداية والنهاية كإجابة نهائية.

14. كيف تبني نظام Text Summarization؟

لبناء نظام تلخيص تجريدي (Abstractive) احترافي:

1. **اختيار النموذج:** استخدام نموذج `BART` أو `T5` (نماذج Seq2Seq ممتازة في التلخيص). 2. **البيانات:** مجموعة بيانات مثل CNN/DailyMail (مقالات إخبارية مع ملخصاتها).
3. **التدريب (Fine-tuning):** تدريب النموذج بحيث يكون المدخل هو المقال، والمخرج المستهدف هو الملخص.
4. **الاستدلال:** استخدام تقنيات مثل `Length Penalty` لضمان عدم توليد ملخصات قصيرة جداً، و `No Repeat N-gram Size` لمنع النموذج من تكرار نفس الجمل.

15. صمّم نظام NLP متكامل لشركة (مثلاً بنك أو خدمة عملاء).

المشروع: نظام ذكي لإدارة تفاعلات عملاء البنك **(Omnichannel NLP System)**

هندسة النظام **(Pipeline):**

1. **قناة الاستقبال (Ingestion):** استقبال النصوص من مصادر متعددة (إيميلات، دردشة حية، واتساب، مراجعات التطبيق).
2. **الموجه الذكي (Intent Classification):** نموذج BERT يصنف نية العميل (استعلام عن رصيد، شكوى بطاقة مفقودة، طلب قرض).
3. **استخراج الكيانات (NER):** نموذج يستخرج المعلومات الحساسة (رقم الحساب، المبلغ، التاريخ) من النص لتمريرها للأنظمة البنكية.
4. **تحليل المشاعر (Sentiment Analysis):** تقييم حالة العميل. إذا كان العميل غاضباً جداً (= Sentiment Very Negative)، يتم تحويل التذكرة فوراً إلى موظف بشري (Human Escalation) متجاوزاً البوت.

5. **الرد الآلي (RAG Chatbot):** للأسئلة الشائعة، يقوم نظام RAG بالبحث في سياسات البنك وتوليد إجابة دقيقة ومخصصة باستخدام LLM آمن (مع Guardrails لمنع الهلوسة).
6. **لوحة القيادة (Analytics Dashboard):** تجميع كل البيانات (المشاعر، النوايا الشائعة) وعرضها للإدارة لتحسين الخدمات.